HUST

ĐẠI HỌC BÁCH KHOA HÀ NỘI

HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

ONE LOVE. ONE FUTURE.

Chương 1
Tổng quan về lưu trữ và xử lý dữ liệu lớn

Thông tin chung về môn học

Tên học phần:	**Lưu trữ và xử lý dữ liệu lớn** **(Big data storage and processing)**
Mã số học phần:	IT4931
Khối lượng:	3(3-1-0-6) – Lý thuyết: 45 tiết – BTL: 15 tiết – Thí nghiệm: 0 tiết

Đề cương học tập

STT	Bài giảng
1	**Tổng quan về lưu trữ và xử lý dữ liệu lớn**
2	**Hệ sinh thái Hadoop (Hadoop ecosystem)**
3	**Hệ thống tập tin phân tán Hadoop HDFS**
4	**Cơ sở dữ liệu phi quan hệ NoSQL - phần 1** Tổng quan
5	**Cơ sở dữ liệu phi quan hệ NoSQL - phần 2** Kiến trúc phân tán phổ biến
6	**Cơ sở dữ liệu phi quan hệ NoSQL - phần 3** Truy vấn SQL trên NoSQL
7	**Hệ thống truyền thông điệp phân tán**
8	**Các kĩ thuật xử lý dữ liệu lớn theo khối - phần 1** Map Reduce
9	**Các kĩ thuật xử lý dữ liệu lớn theo khối - phần 2** Apache Spark
10	**Các kĩ thuật xử lý luồng dữ liệu lớn** Spark Streaming
11	**Kiến trúc dữ liệu lớn** Lambda architecture
12	**Phân tích dữ liệu lớn** Spark ML

Tổng dung lượng dữ liệu 2020

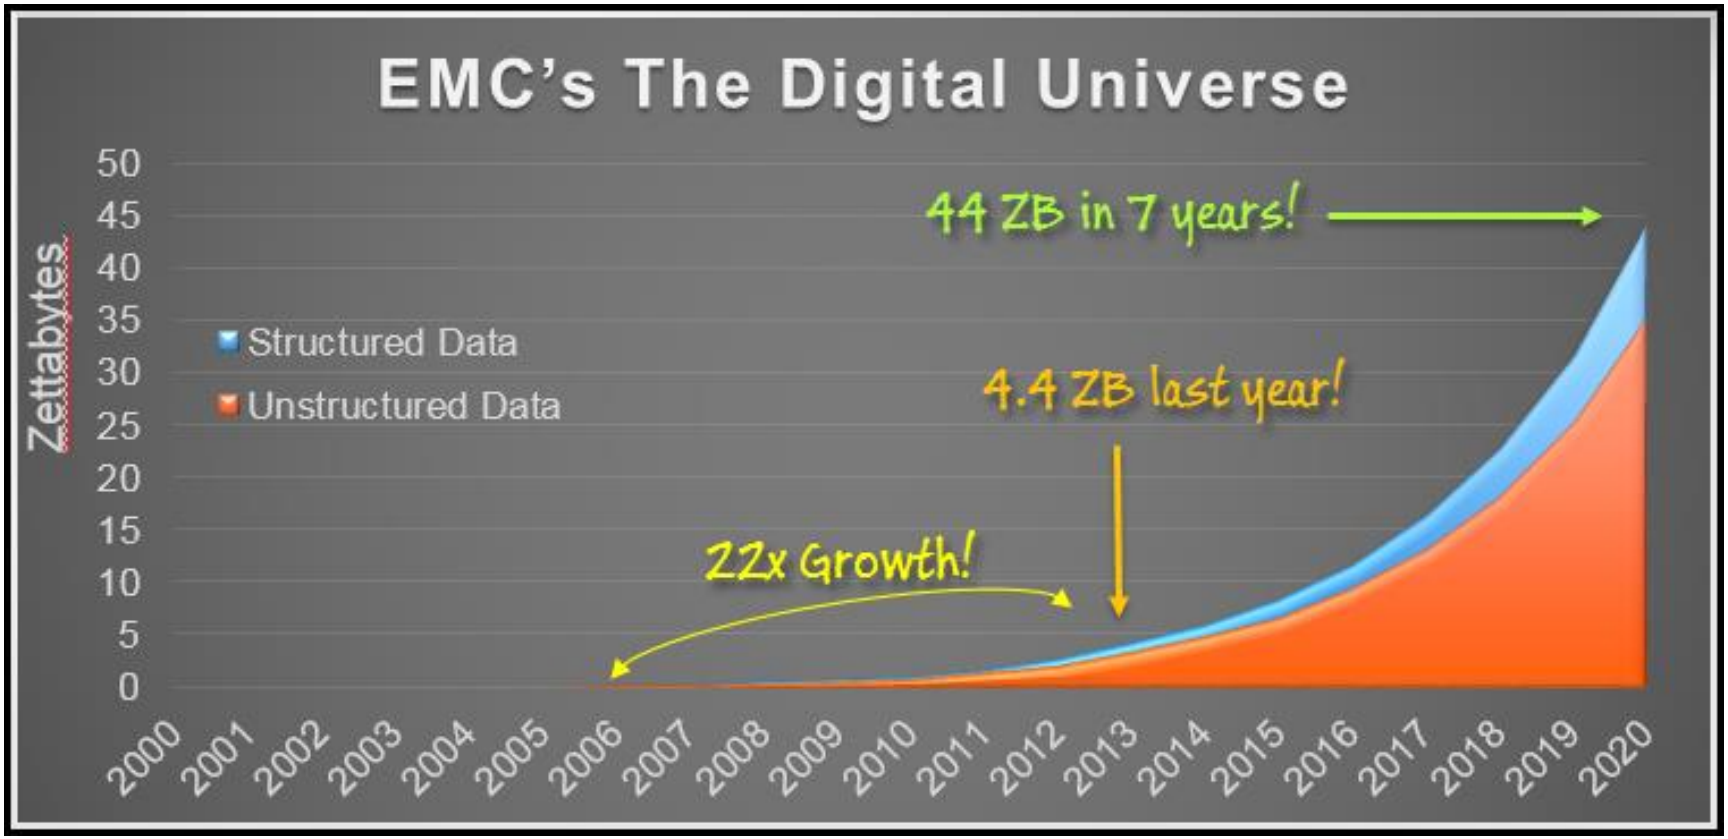

Tổng dung lượng dữ liệu 2025

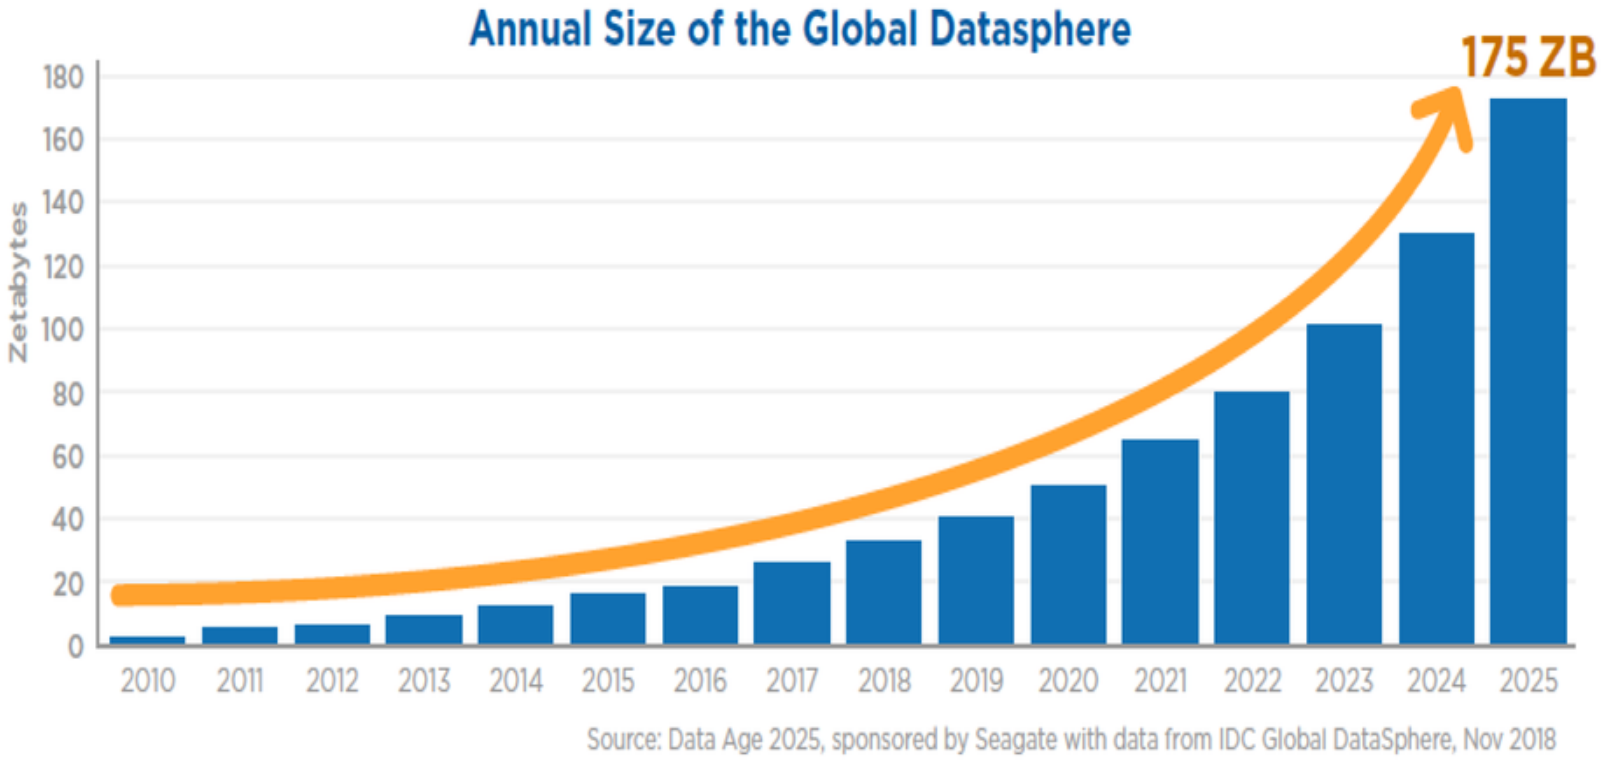

Hình dung về độ lớn của dữ liệu

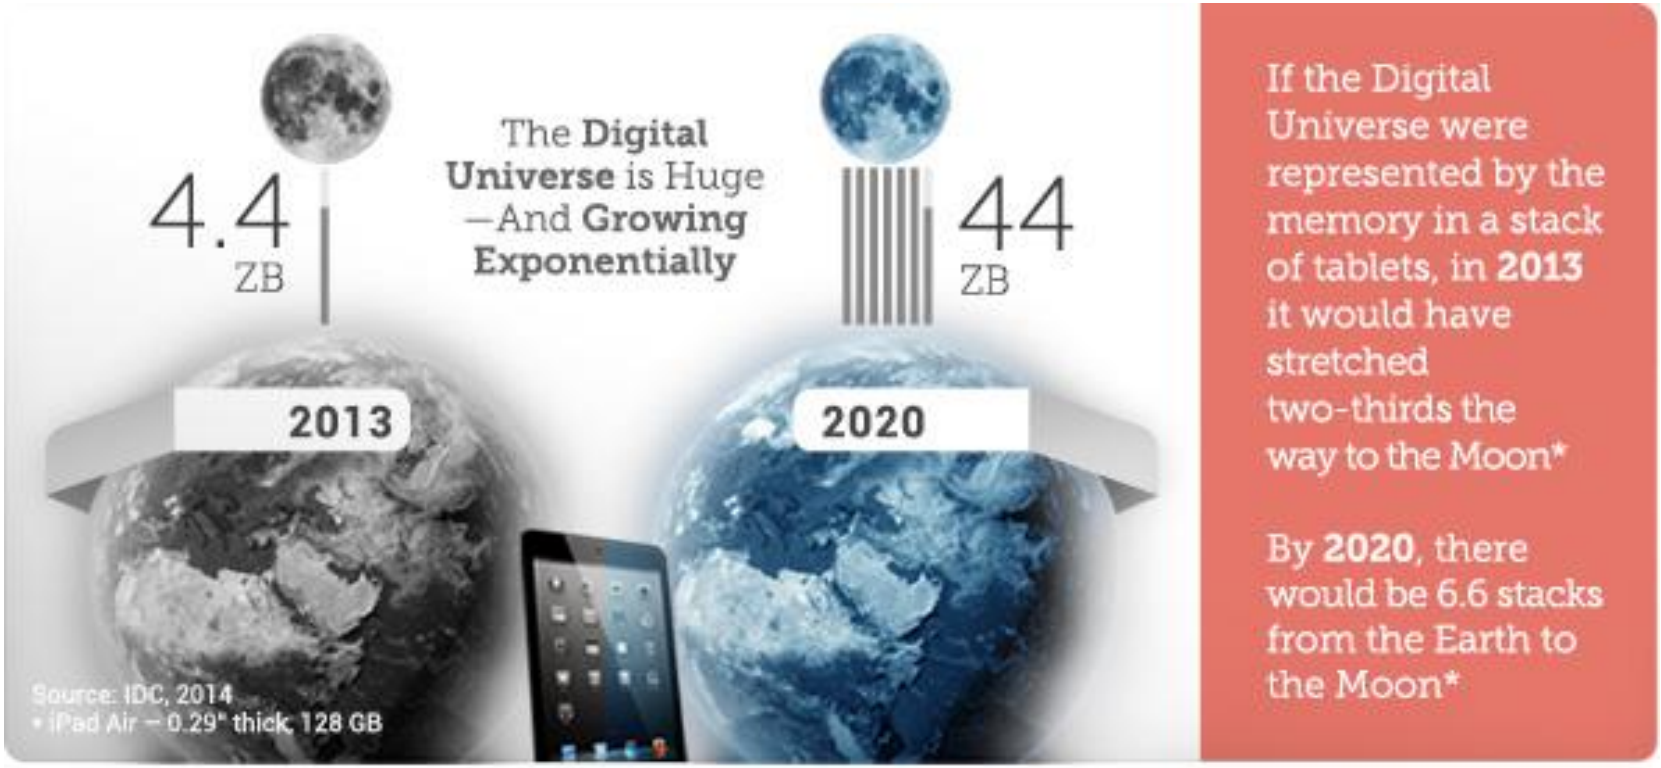

Khoa học dữ liệu: Bước phát triển thứ 4 của khoa học khám phá

$$\left(\frac{\dot{a}}{a}\right)^2 = \frac{4\pi G\rho}{3} - \mathrm{K}\frac{c^2}{a^2}$$

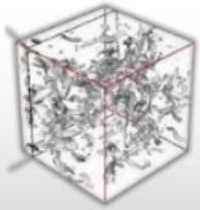

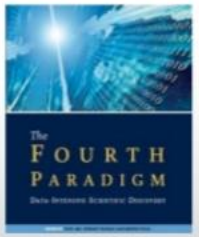

Experimental	Theoretical	Computational	The Fourth Paradigm
Thousand years ago	Last few hundred years	Last few decades	Today and the Future
Description of natural phenomena	*Newton's laws, Maxwell's equations...*	*Simulation of complex phenomena*	*Unify theory, experiment and simulation with large multidisciplinary Data* *Using data exploration and data mining (from instruments, sensors, humans...)* *Distributed Communities*

Nói về dữ liệu lớn năm 2008

http://www.wired.com/wired/issue/16-07

September 2008

Nói về dữ liệu lớn năm 2014

THE AVERAGE PERSON TODAY PROCESSES MORE DATA IN A SINGLE DAY THAN A PERSON IN THE 1500'S DID IN AN ENTIRE LIFETIME

LOOK TO THE LEFT, and you see Times Square at dusk. Look to the right, and you see the same location at midmorning. Internationally acclaimed photographer Stephen Wilkes's time-altering image of New York's Times Square is part of his body of work titled ***Day to Night***.

The image was created by blending more than 1,400 separate photos taken over the course of 15 hours—a meticulous process that took him nearly three months.

PHOTO: STEPHEN WILKES

Dữ liệu lớn ngày nay

Những con số về tốc độ sinh dữ liệu

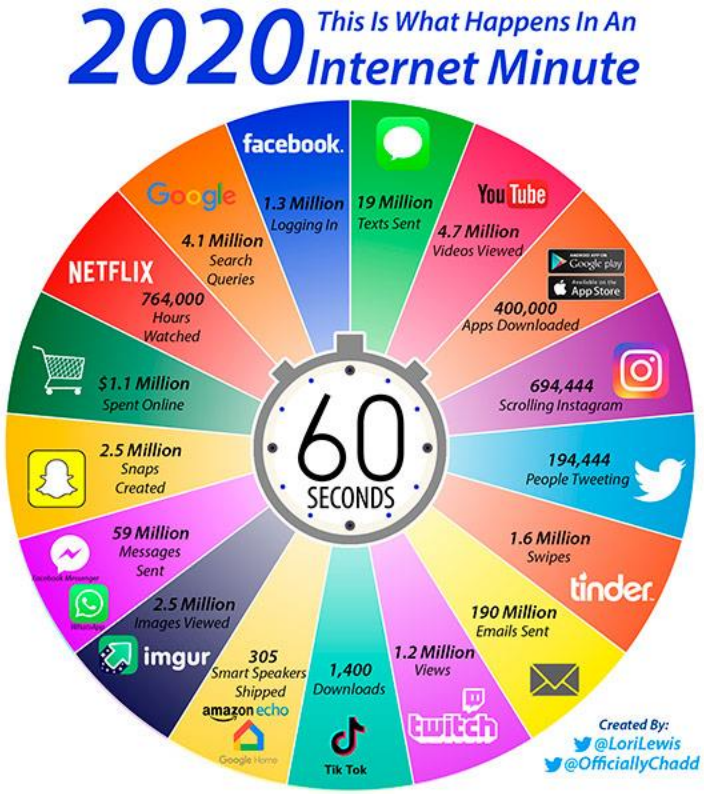

Các nguồn tạo ra dữ liệu lớn

- Thương mại điện tử
- Mạng xã hội
- Internet vạn vật (IoT)
- Các thử nghiệm dữ liệu lớn (tin sinh học, vật lý lượng tử, vvv)

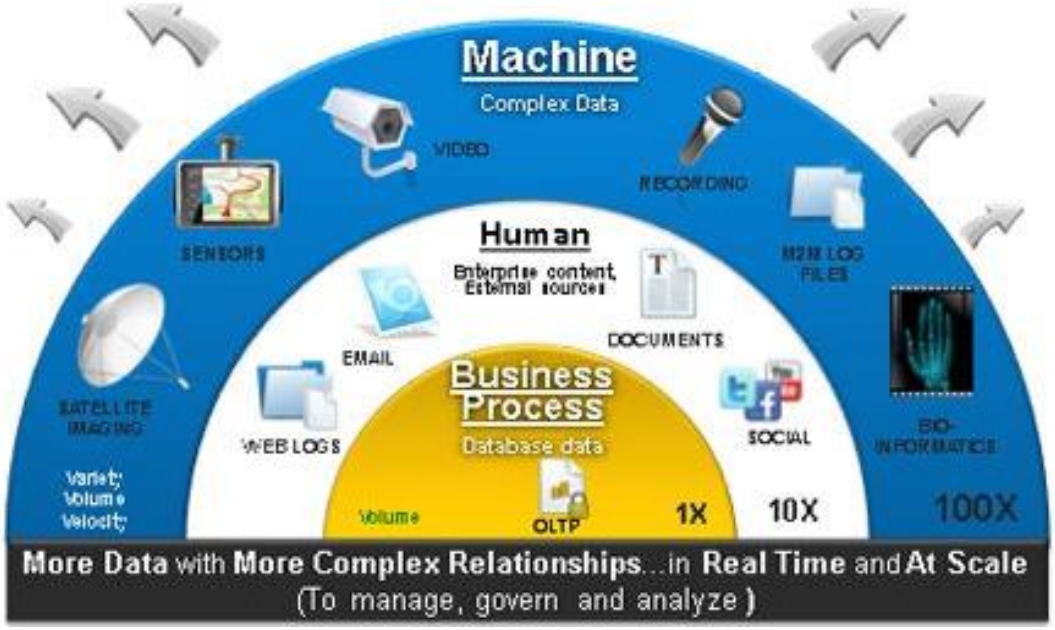

Dữ liệu được ví như nguồn tài nguyên dầu mỏ mới

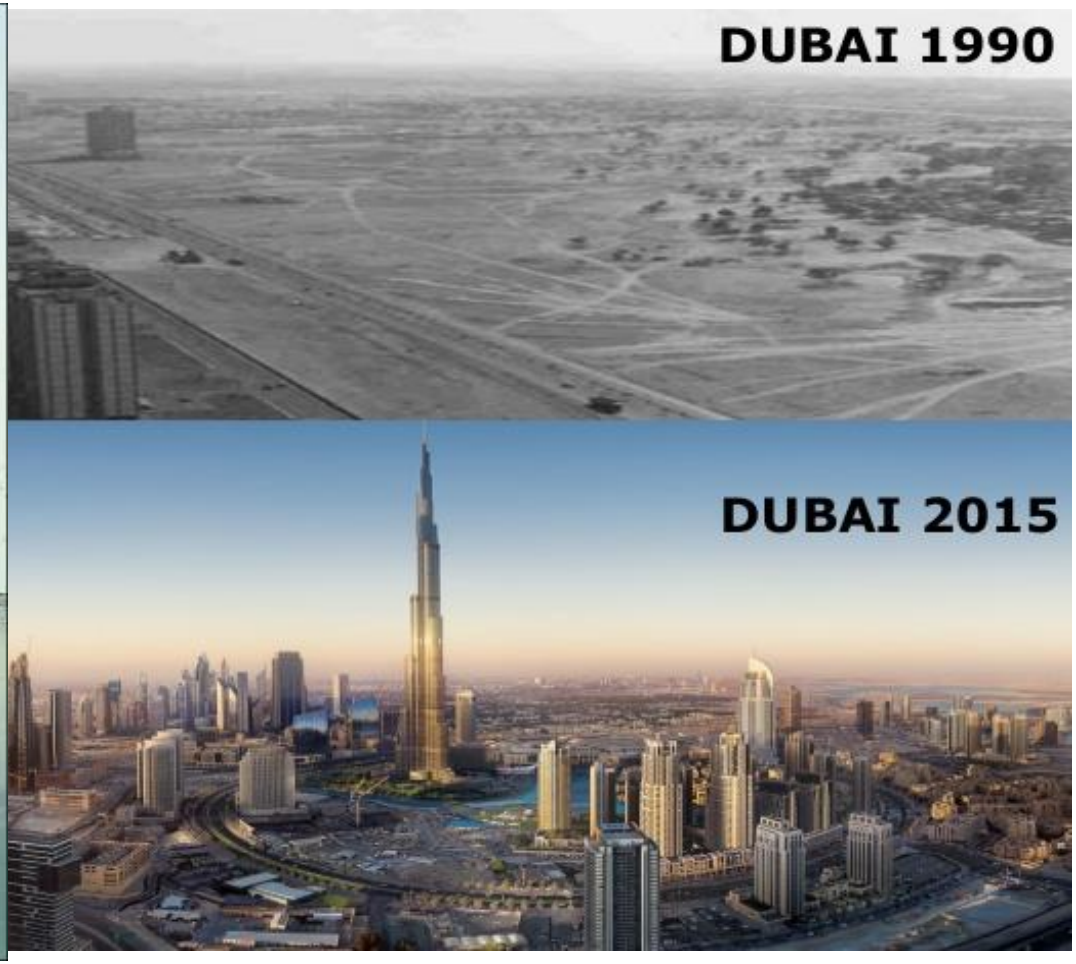

Đặc điểm 5'V của dữ liệu lớn

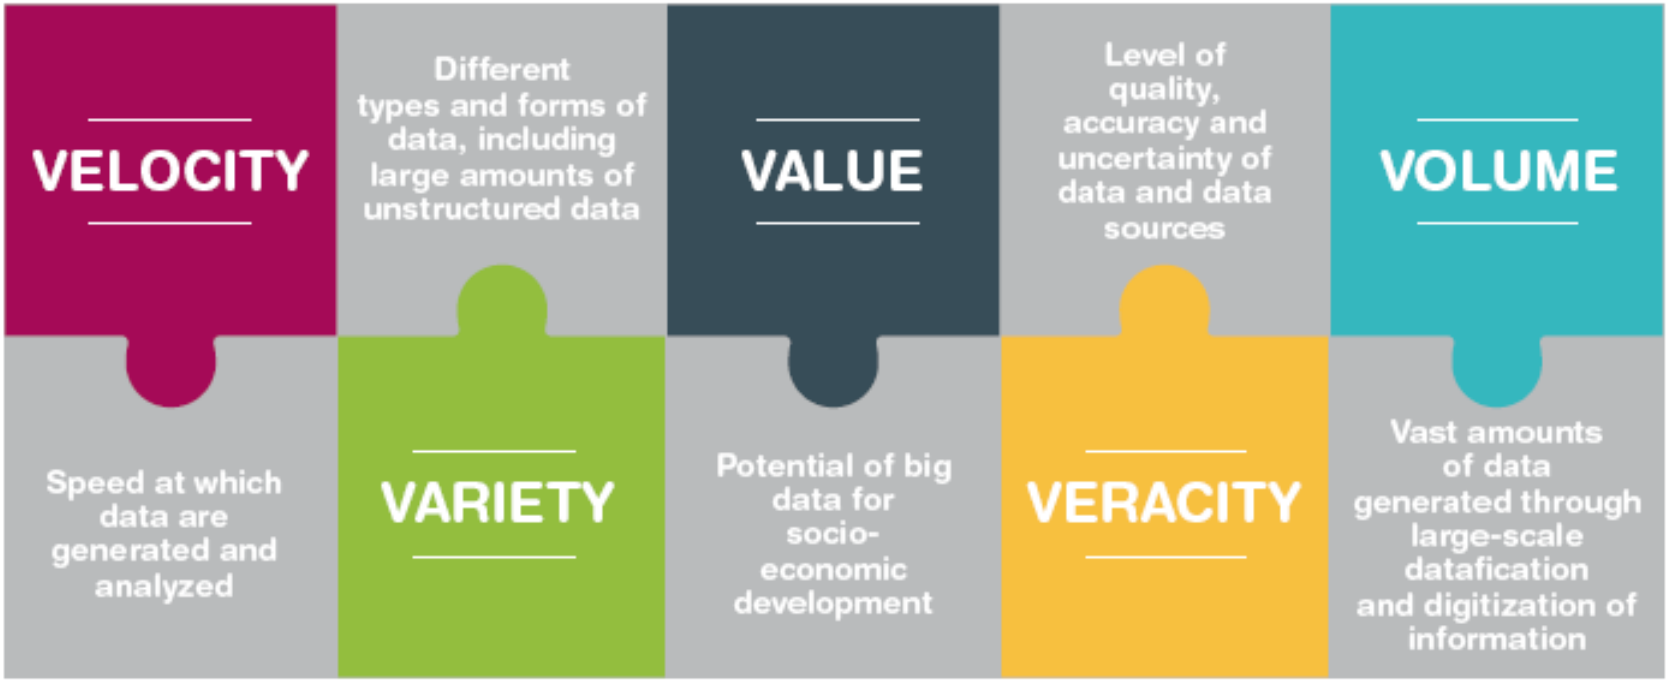

Dữ liệu lớn là tập dữ liệu quá lợn hoặc là quá phức tạp mà các nền tảng lưu trữ và xử lý dữ liệu truyền thống không đáp ứng được.

Dữ liệu lớn – giá trị mang lại lớn

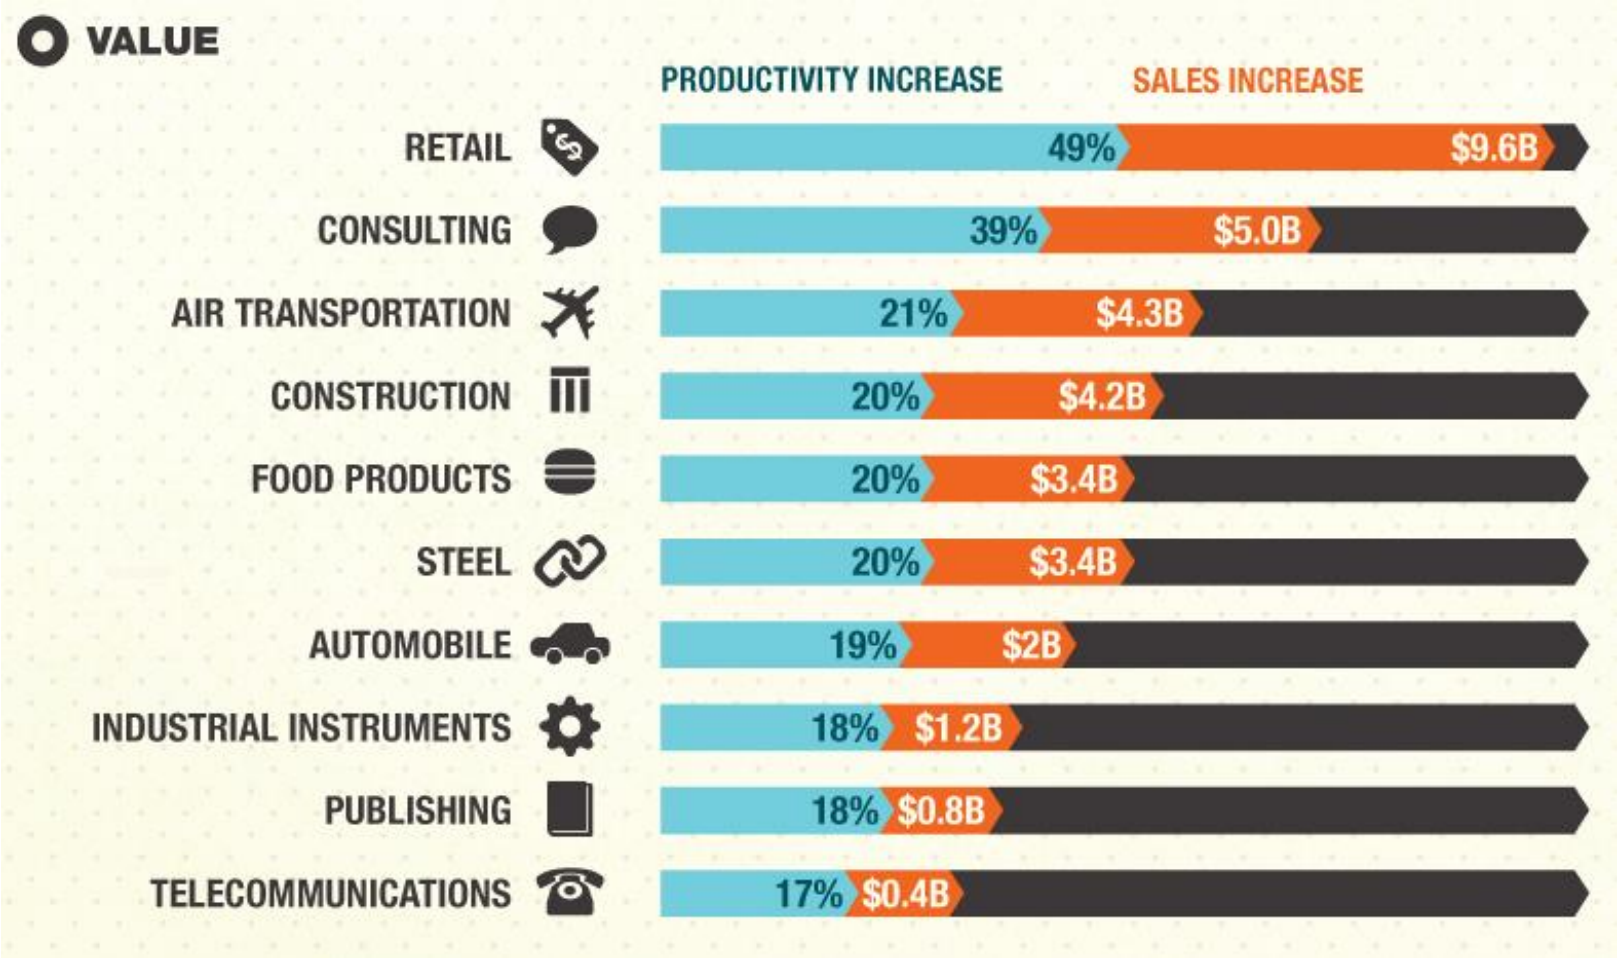

source: wipro.com

Amazon

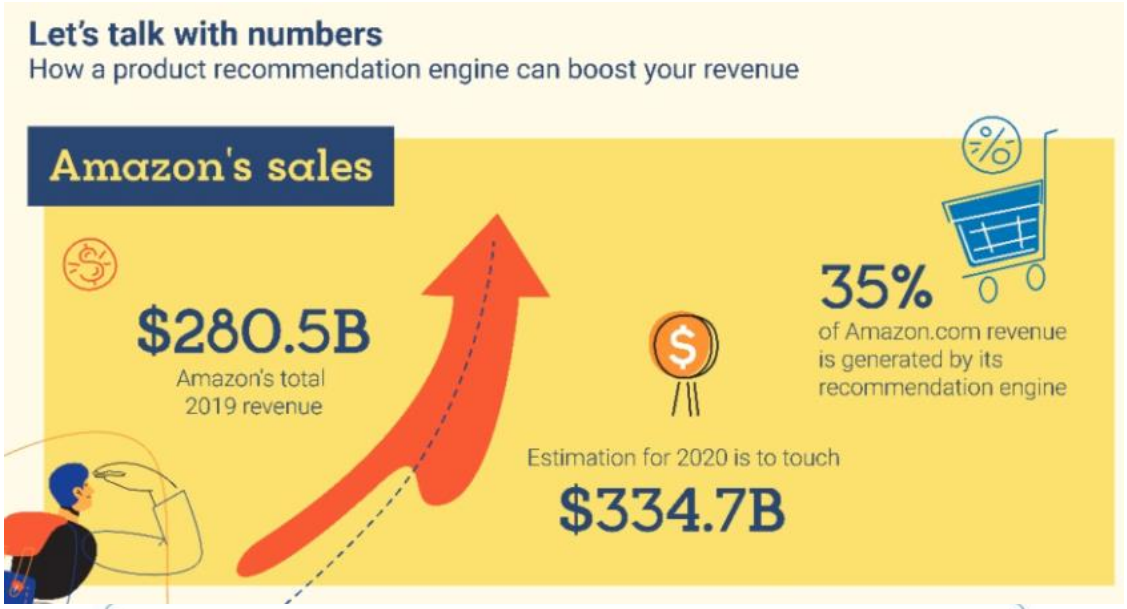
Let's talk with numbers
How a product recommendation engine can boost your revenue
Amazon's sales
$280.5B
Amazon's total 2019 revenue
35%
of Amazon.com revenue is generated by its recommendation engine
Estimation for 2020 is to touch
$334.7B

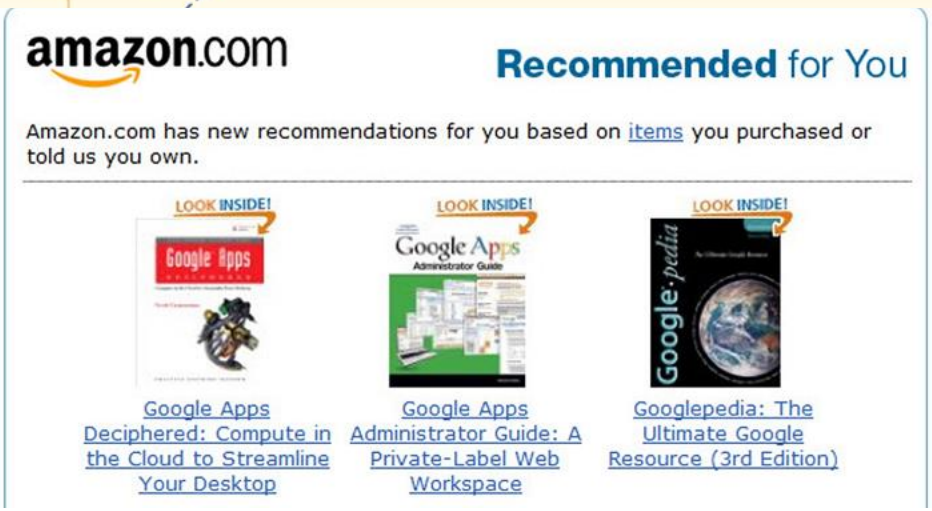
amazon.com
Recommended for You
Amazon.com has new recommendations for you based on items you purchased or told us you own.
LOOK INSIDE!
Google Apps Deciphered: Compute in the Cloud to Streamline Your Desktop
LOOK INSIDE!
Google Apps Administrator Guide: A Private-Label Web Workspace
LOOK INSIDE!
Googlepedia: The Ultimate Google Resource (3rd Edition)

Tiktok

- TikTok has 1.04 billion monthly active users globally as of 2024.
- TikTok users spend 58 minutes and 24 seconds on the app daily as of 2024.
- The majority of TikTok users are between the ages of 18 to 34, at 69.3%.

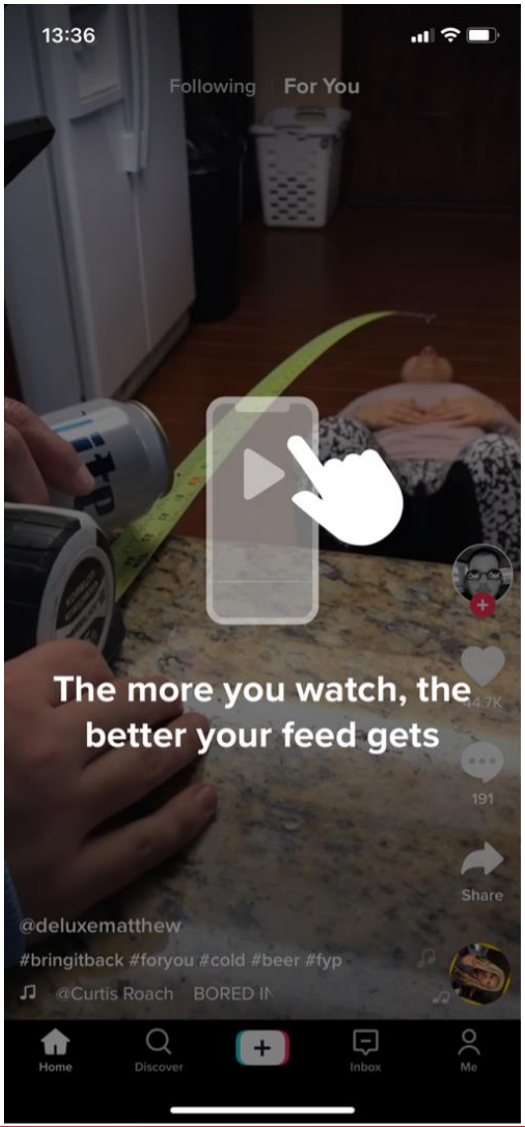

Khai thác dữ liệu lớn trong giáo dục

Khai thác dữ liệu lớn trong khoa học chăm sóc sức khoẻ

- Giảm chi phí điều trị, các xét nghiệm dư thừa
- Dự đoán quy mô đại dịch, khuyến nghị các biện pháp ứng phó
- Ngăn ngừa sớm các bệnh có thể gặp trong tương lai

Khai thác dữ liệu lớn trong quản lý nhà nước

- Các chương trình phúc lợi xã hội
  - Nắm bắt nhanh chóng các vấn đề xã hội (việc làm, tội phạm, môi trường, vvv)
  - Khuyến nghị các biện pháp đối phó
- An ninh thông tin
  - Trốn thuế
  - Lừa đảo

Khai thác dữ liệu lớn trong khoa học khám phá

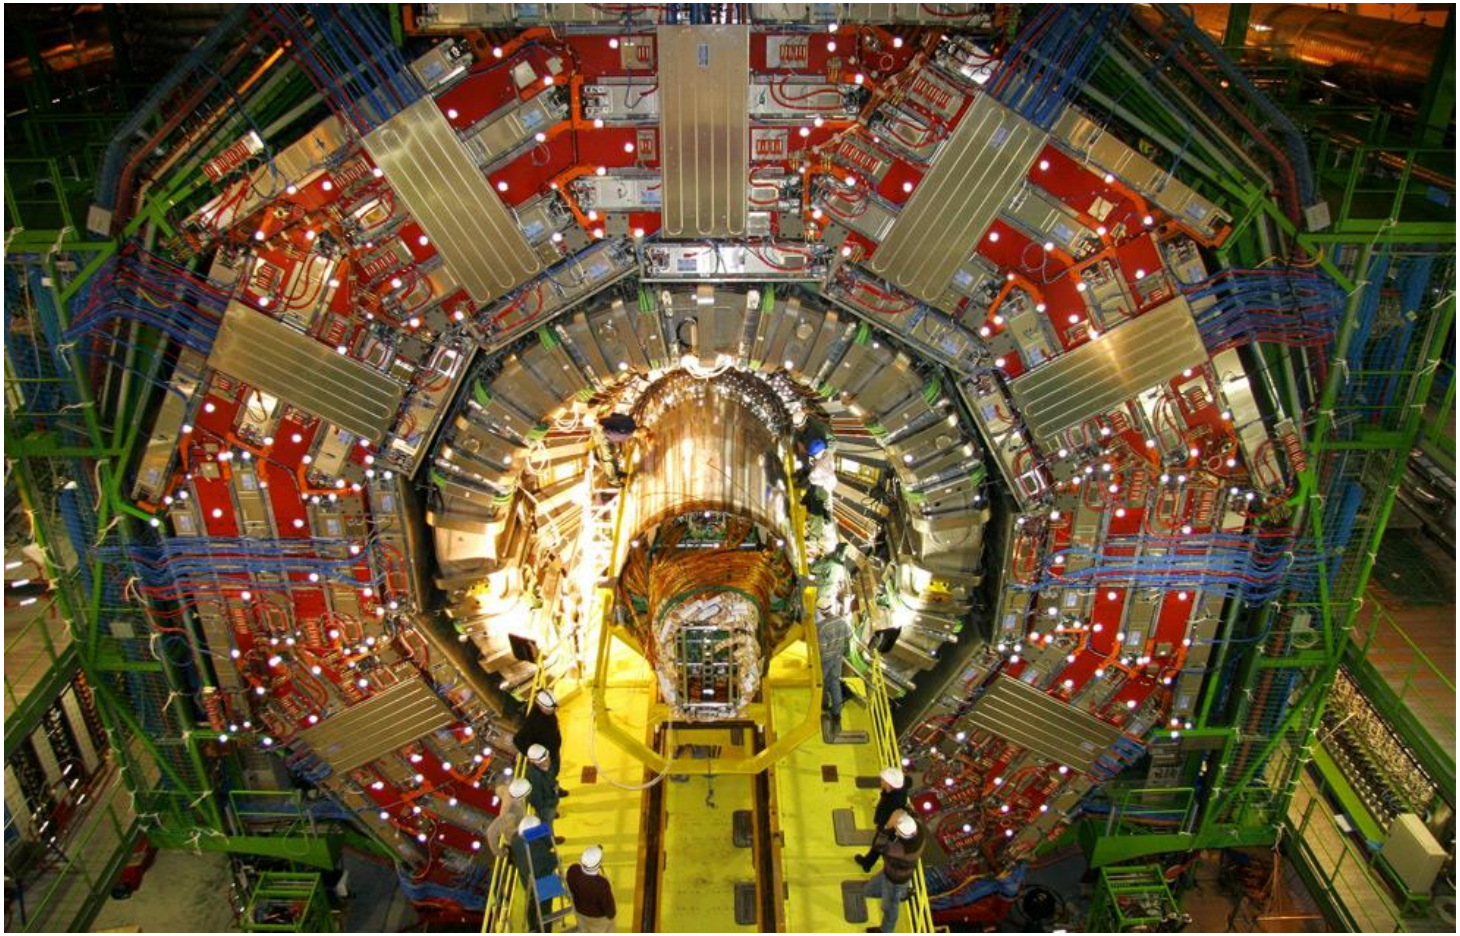

CERN’s Large Hydron Collider (LHC) generates 15 PB a year

The world is running out of data to train AI

LARGE LANGUAGE MODEL HIGHLIGHTS (FEB/2024)

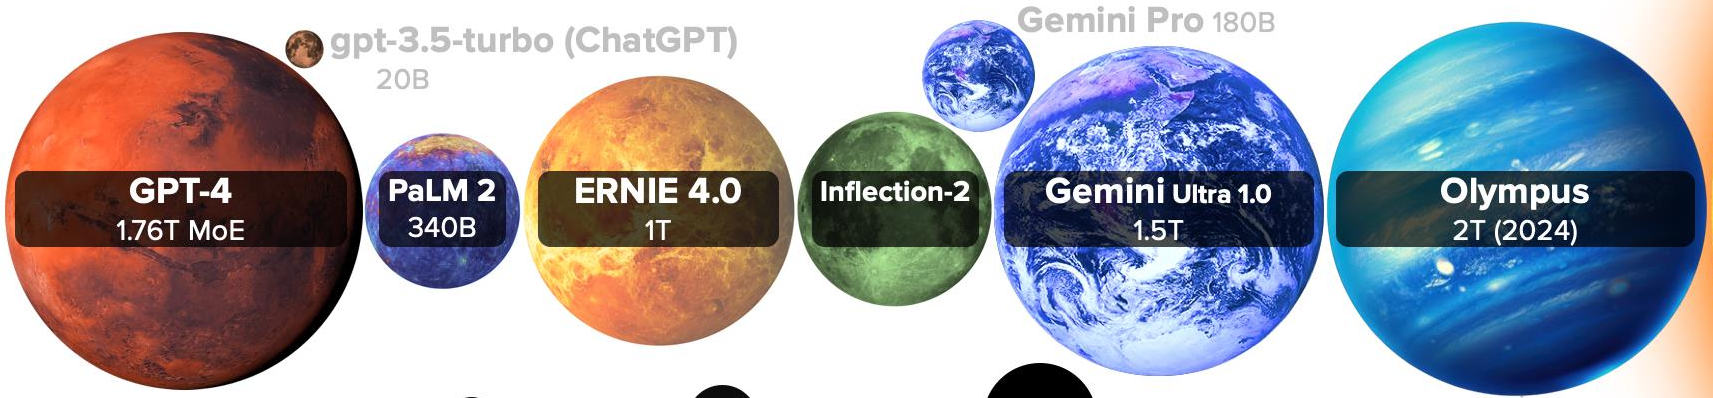

Nano
Mamba 2.8B
phi-2 2.7B
...

XS
Pythia 12B
Mistral 7B
Zephyr 7.3B
Gauss
StripedHyena 7B
Persimmon-8B
DeciLM-7B
SOLAR 10.7B
OLMo 7B

30B **Small**
Palmyra 20B
C1.2
Retro 48B
MPT-30B
Grok-1 33B
Yi-34B
Mixtral 8x7B
...

70B **Medium**
Command 52B
StableLM 65B
Llama 1 65B
Luminous Supreme
Llama 2 70B
Perplexity 70B Online
Qwen-72B
DeepSeek 67B

180B **Large**
Yuan 2.0 102.6B
InternLM 104B
Jurassic-2
Falcon 180B
Claude 2.1
Mistral-medium
...

Parameters
AI lab/group

Sizes linear to scale. Selected highlights only. All models are available. All models are Chinchilla-aligned (20:1 tokens:parameters) https://lifearchitect.ai/chinchilla/ All 200+ models: https://lifearchitect.ai/models-table/ Alan D. Thompson. 2023-2024.

LifeArchitect.ai/models

10 công ty lớn nhất (1998-2018)

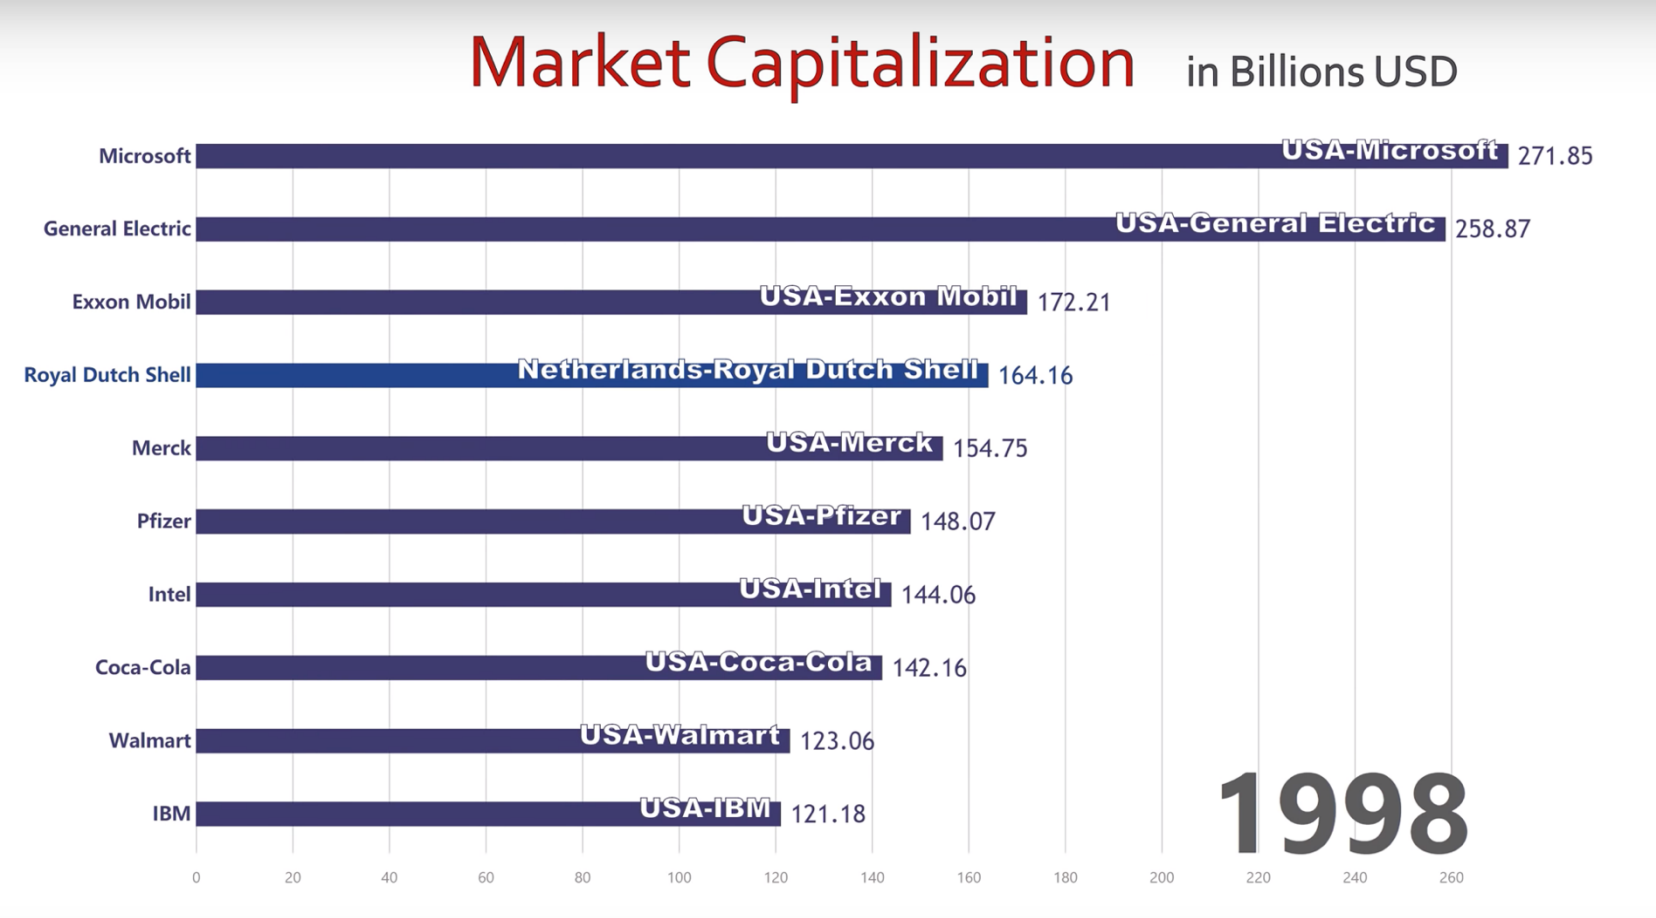

https://www.youtube.com/watch?v=fobx4wIS6W0

10 công ty lớn nhất (1998-2018)

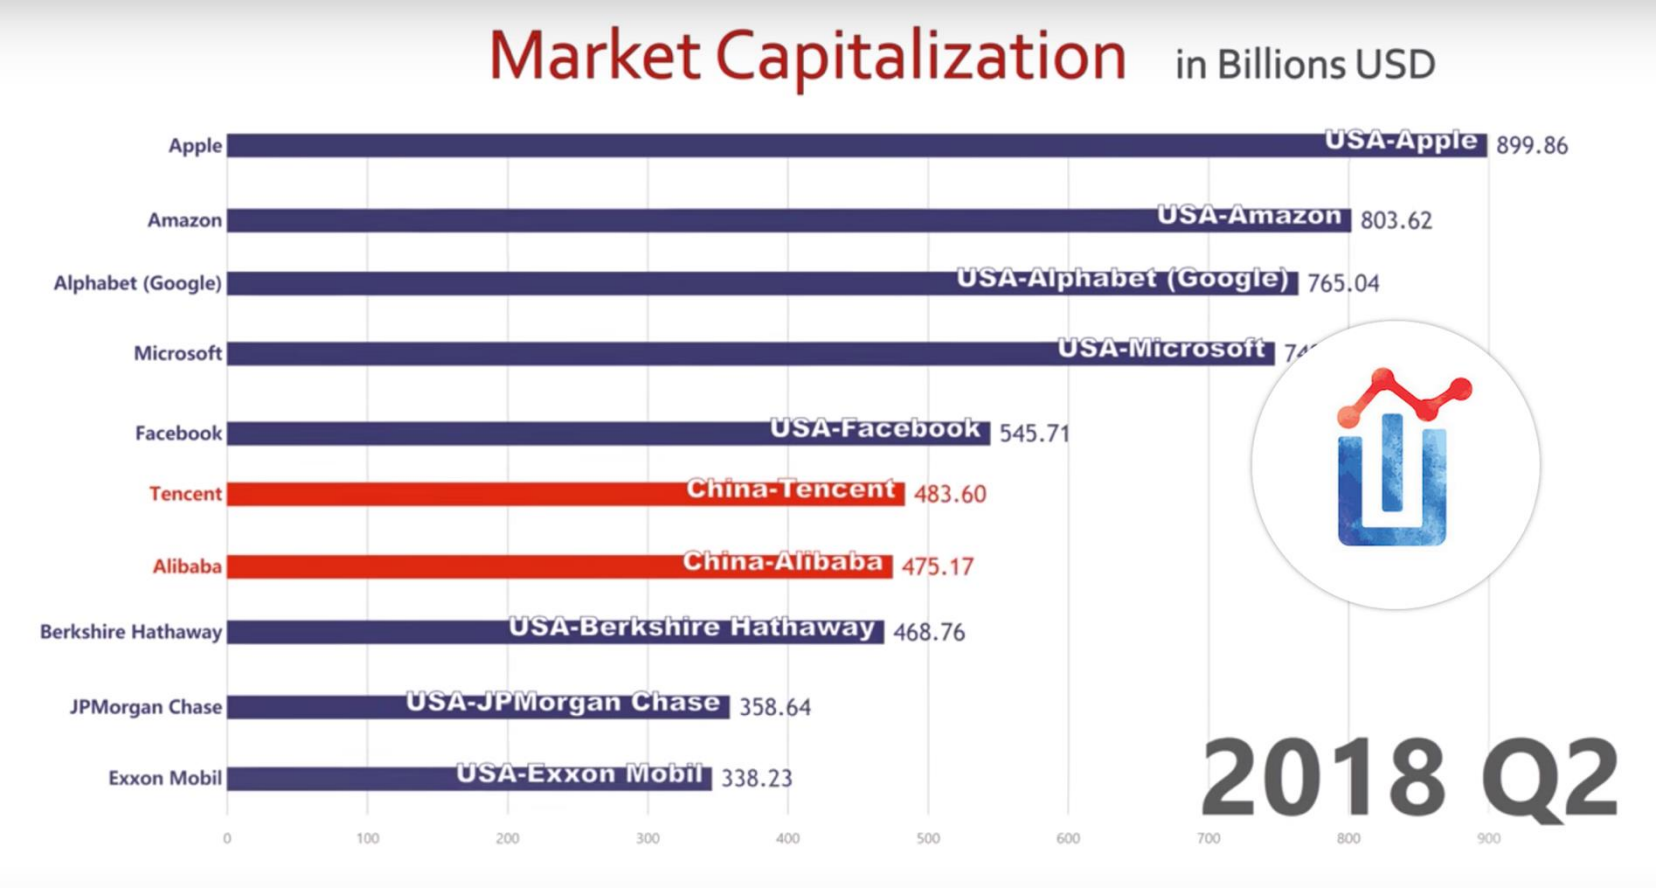

Các tầng công nghệ cho dữ liệu lớn

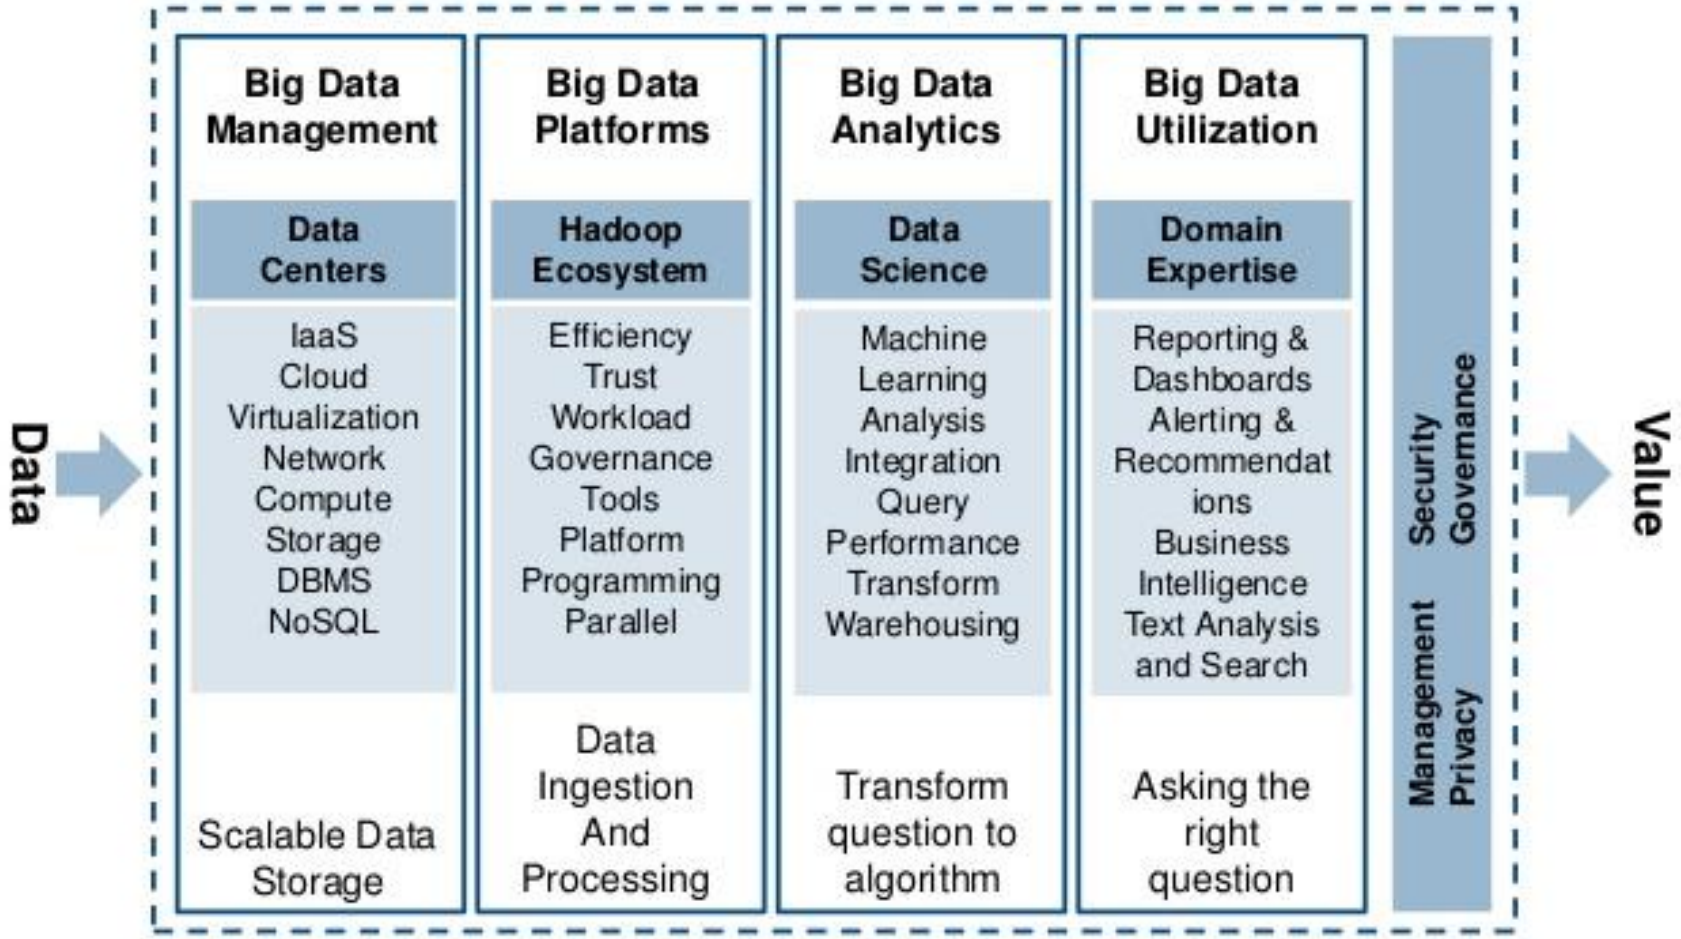

Quản lý dữ liệu phải khả mở

- Scalability
  - Khả năng quản lý lượng dữ liệu lớn không ngừng tăng lên theo thời gian.
- Accessibility
  - Cho phép đọc ghi I/O dữ liệu hiệu quả.
- Transparency
  - Truy cập dữ liệu dễ dàng, vị trí lưu trữ dữ liệu trên hệ thống là trong suốt với người dùng cuối.
- Availability
  - Khả năng chống chịu lỗi, khi tăng số lượng người dùng, khi hỏng hóc.

Tốc độ I/O phổ biến

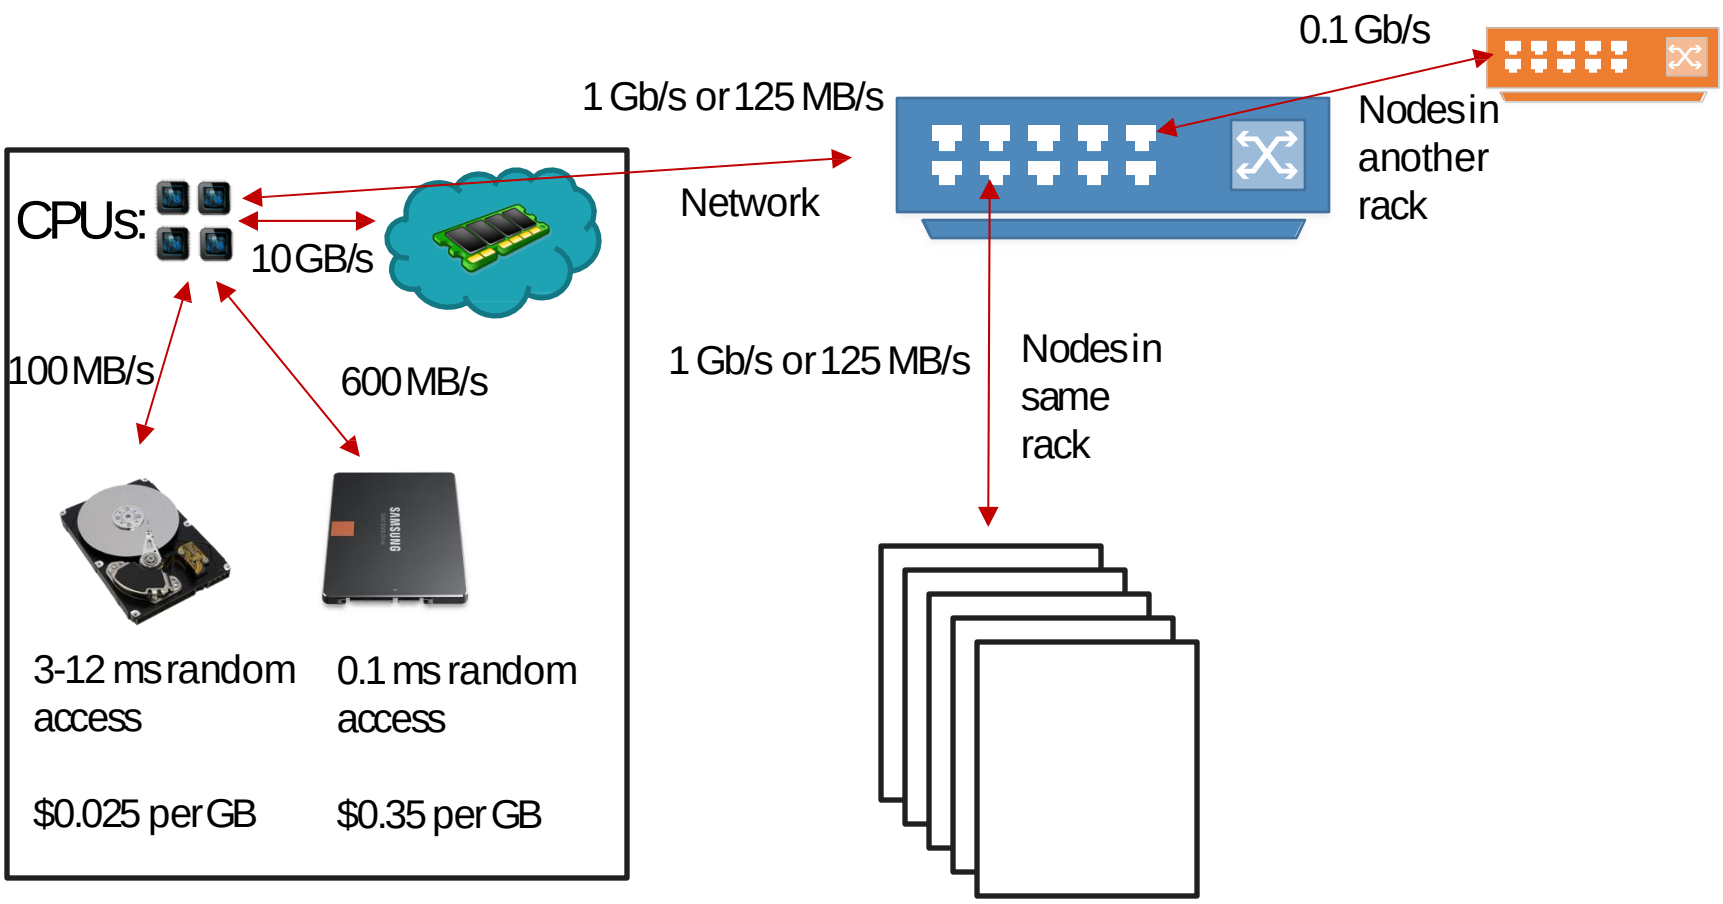

Xử lý và tích hợp dữ liệu phải khả mở

- Tích hợp dữ liệu
  - Dữ liệu có định dạng khác nhau
  - Dữ liệu tồn tại ở các mô hình và lược đồ dữ liệu khác nhau
  - Các vấn đề liên quan đến an toàn an ninh thông tin, quyền riêng tư
- Xử lý dữ liệu
  - Xử lý khối lượng dữ liệu rất lớn
  - Xử lý luồng dữ liệu lớn
  - Xử lý dữ liệu song song, phân tán truyền thống (OpenMP, MPI)
    - Phức tạp, khó học
    - Khả năng khả mở có giới hạn
    - Cơ chế chịu lỗi kém
    - Chi phí hạ tầng đắt đỏ
  - Kiến trúc xử lý dữ liệu luồng dữ liệu lớn
    - Spark mini-batch
    - Apache Flink

Các giải thuật phân tích dữ liệu khả mở

- Làm nhỏ lại dữ liệu cho phù hợp với các giải thuật truyền thống
  - Eg. Sub-sampling
  - Eg. Principal component analysis
  - Eg. Feature extraction and feature selection
- Song song hoá các giải thuật học máy
  - Eg. k-nn classification based on MapReduce
  - Eg. scaling-up support vector machines (SVM) by a divide and-conquer approach

Eg. Sự bùng nổ số chiều trong dữ liệu (Curse of dimensionality)

- Số lượng mẫu cần cho mô hình học tăng lên khi số chiều dữ liệu tăng
- Trong thực tiễn: Số lượng mẫu để học thường cố định
  - => Độ chính xác của mô hình giảm khi tăng số chiều trong dữ liệu học

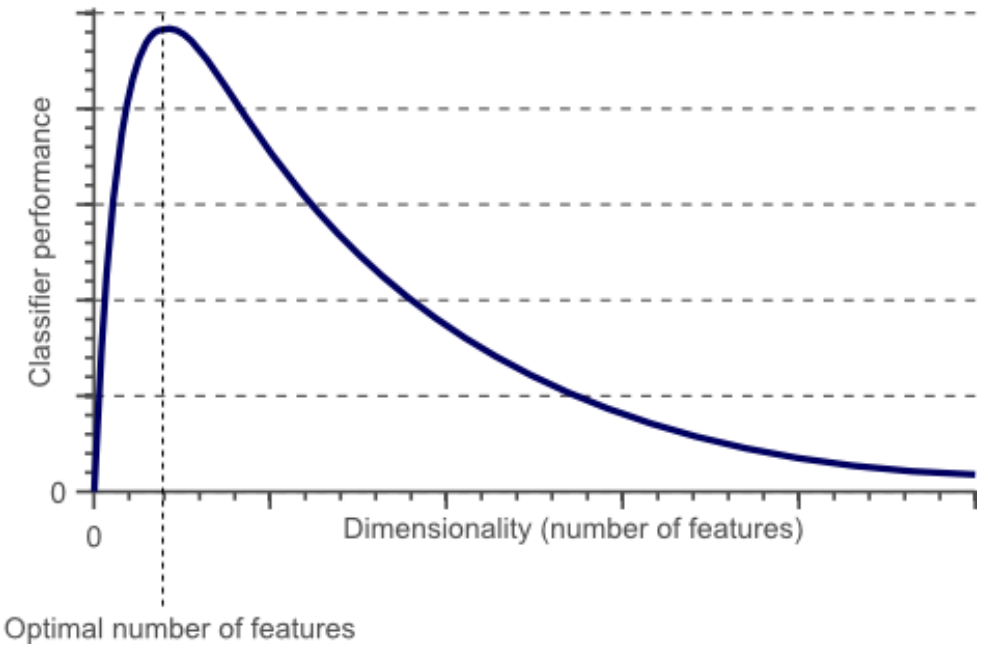

Sử dụng và trực quan hoá dữ liệu lớn

- Cần kiến thức chuyên gia
- Cần kỹ thuật và công cụ để hỗ trợ hiệu quả việc trình diễn và hiểu về dữ liệu lớn

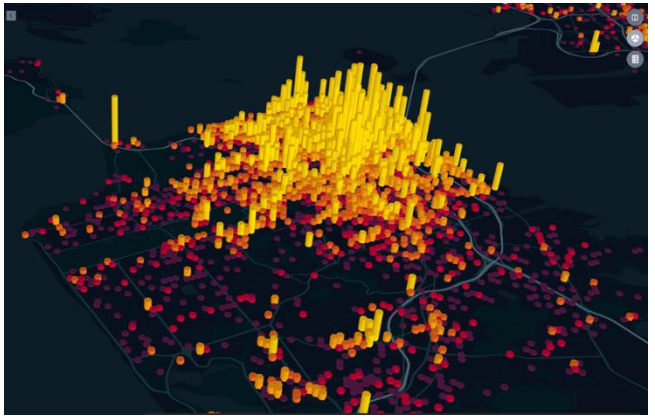

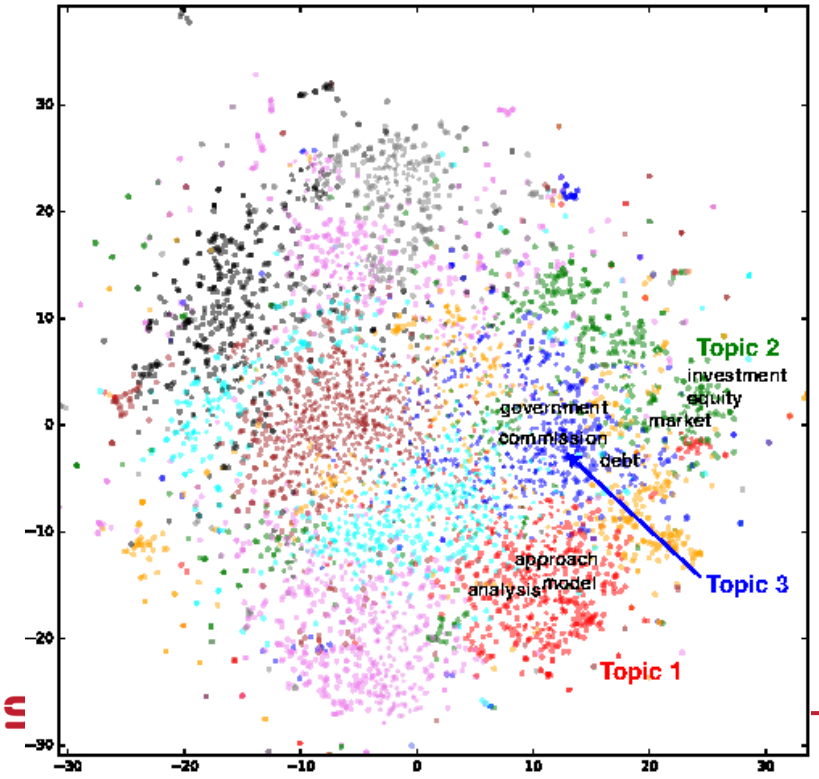

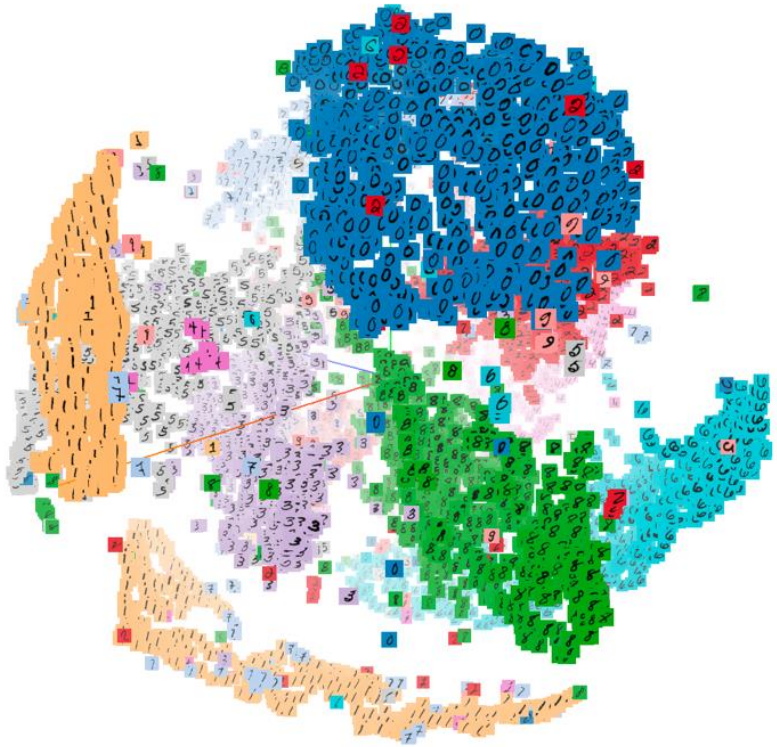

Bảo mật và quyền riêng tư

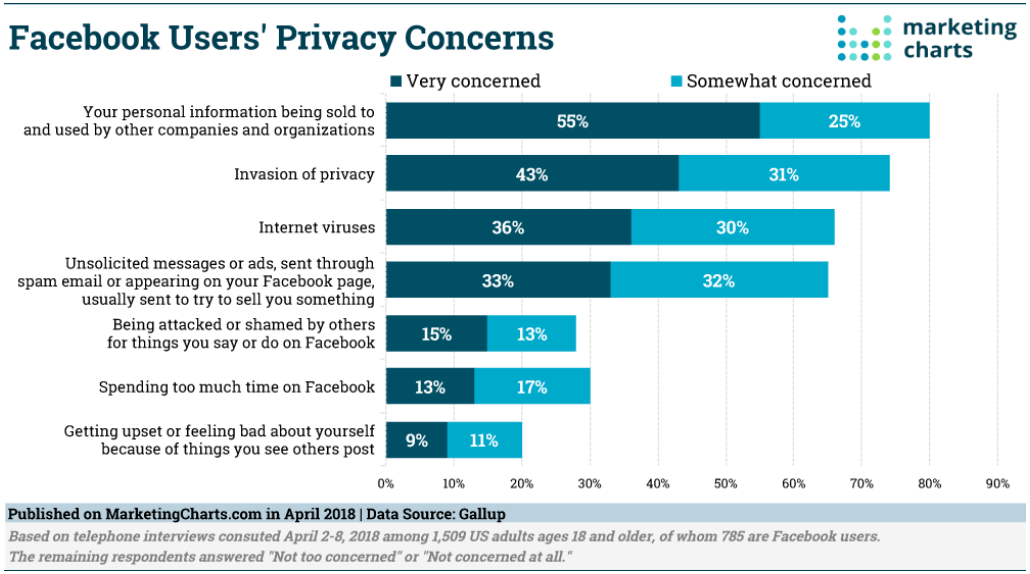

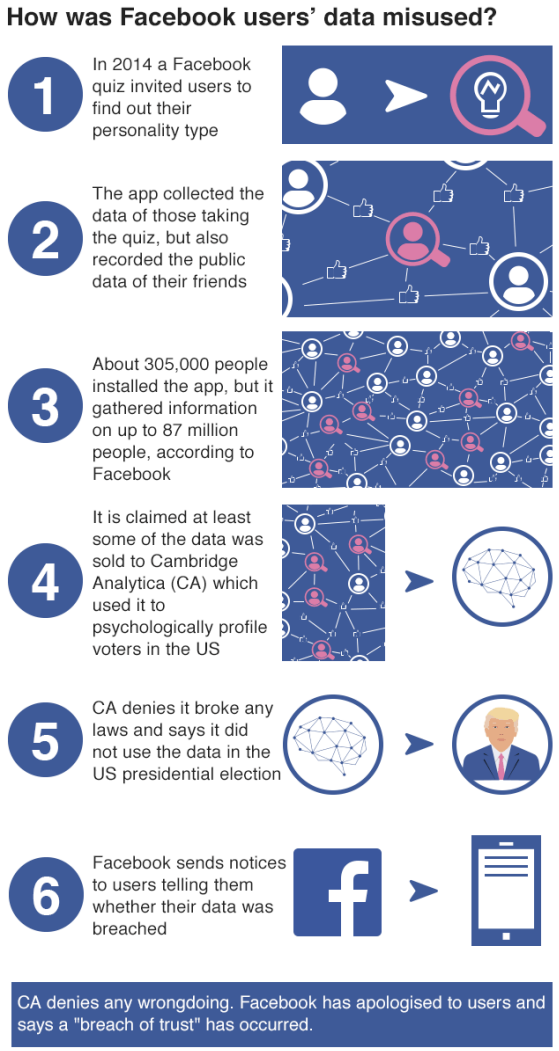

Thiếu hụt nhân lực liên quan tới dữ liệu lớn

Table 2. Summary Demand Statistics

DSA Framework Category	Number of Postings in 2015	Projected 5-Year Growth	Estimated Postings for 2020	Average Time to Fill (Days)	Average Annual Salary
All	2,352,681	15%	2,716,425	45	$80,265
Data-Driven Decision Makers	812,099	14%	922,428	48	$91,467
Functional Analysts	770,441	17%	901,743	40	$69,162
Data Systems Developers	558,326	15%	641,635	50	$78,553
Data Analysts	124,325	16%	143,926	38	$69,949
Data Scientists & Advanced Analysts	48,347	28%	61,799	46	$94,576
Analytics Managers	39,143	15%	44,894	43	$105,909

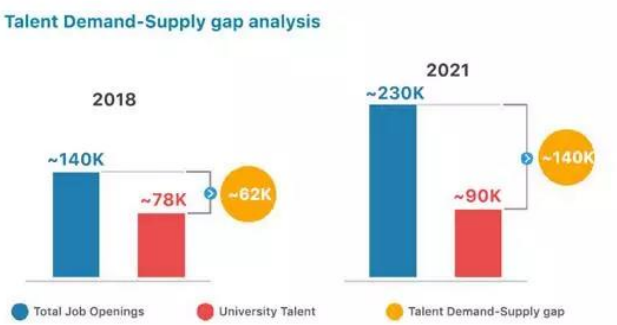

Nhóm các kỹ năng cần thiết theo vị trí

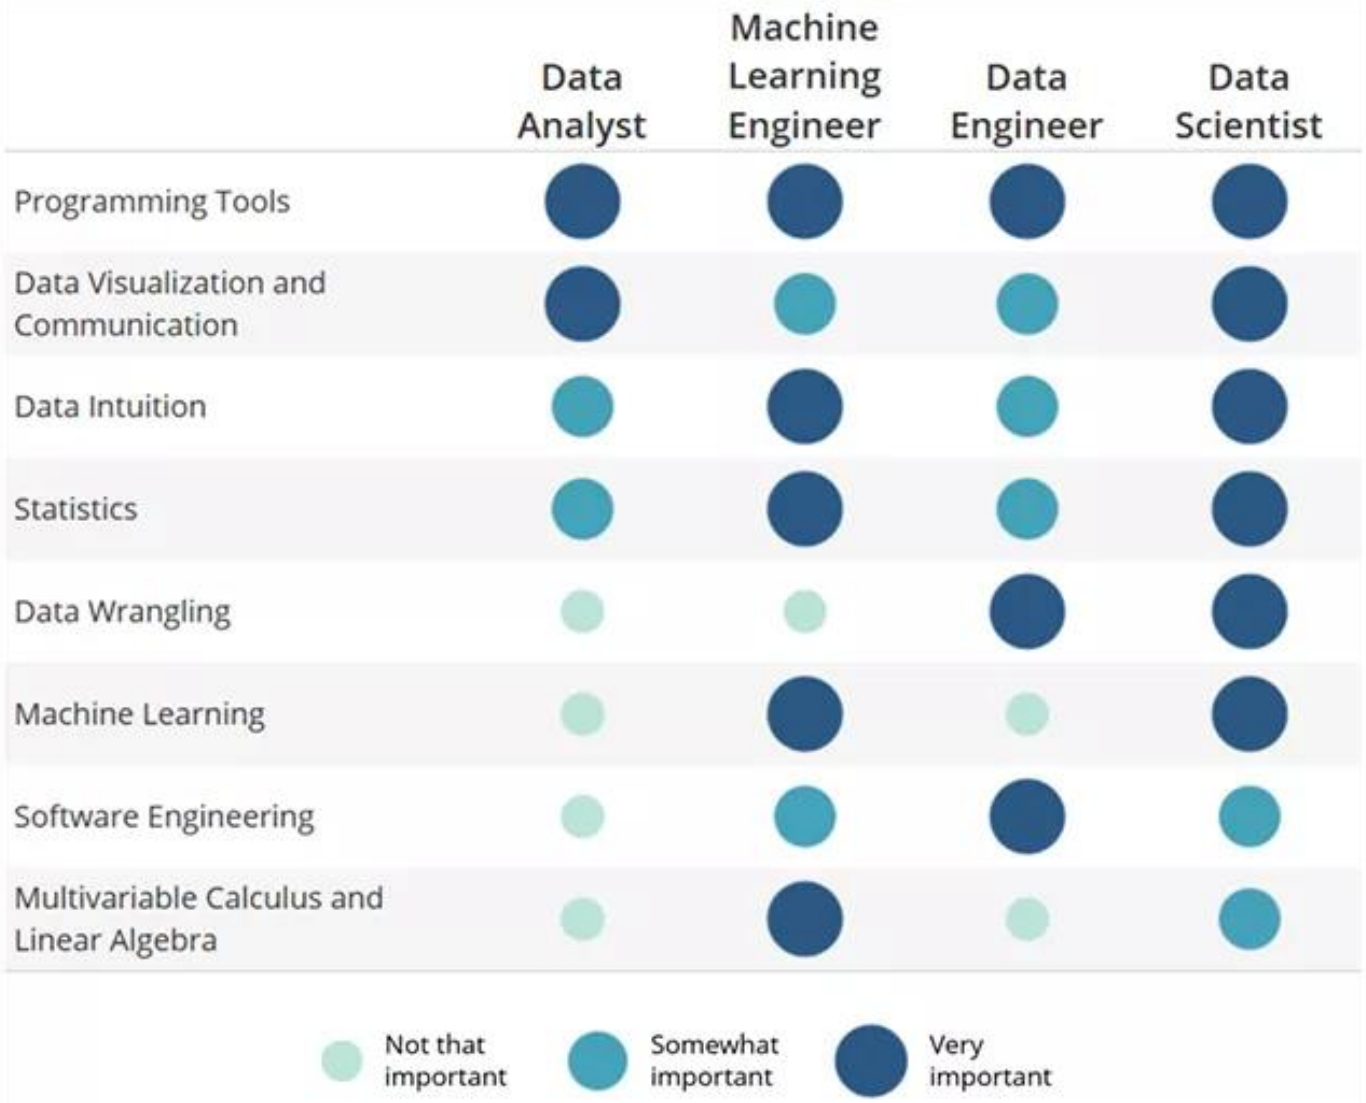

Gợi ý tìm hiểu về dữ liệu lớn

- Học lập trình
  - Coursera
  - Udacity
  - Freecodecamp
  - Codecademy
- Học học máy, toán, toán thống kê
- Kaggle
- Hadoop, NoSQL, Spark
- Các công cụ báo cáo và trực quan hoá
  - Tableau
  - Pentahoo
- Gặp gỡ và chia sẻ
- Tìm cố vấn
- Thực tập, dự án

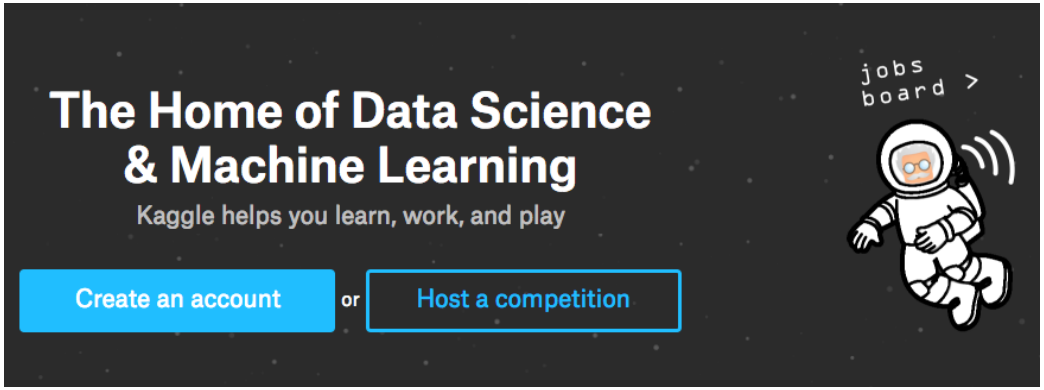

Quy trình làm khoa học dữ liệu

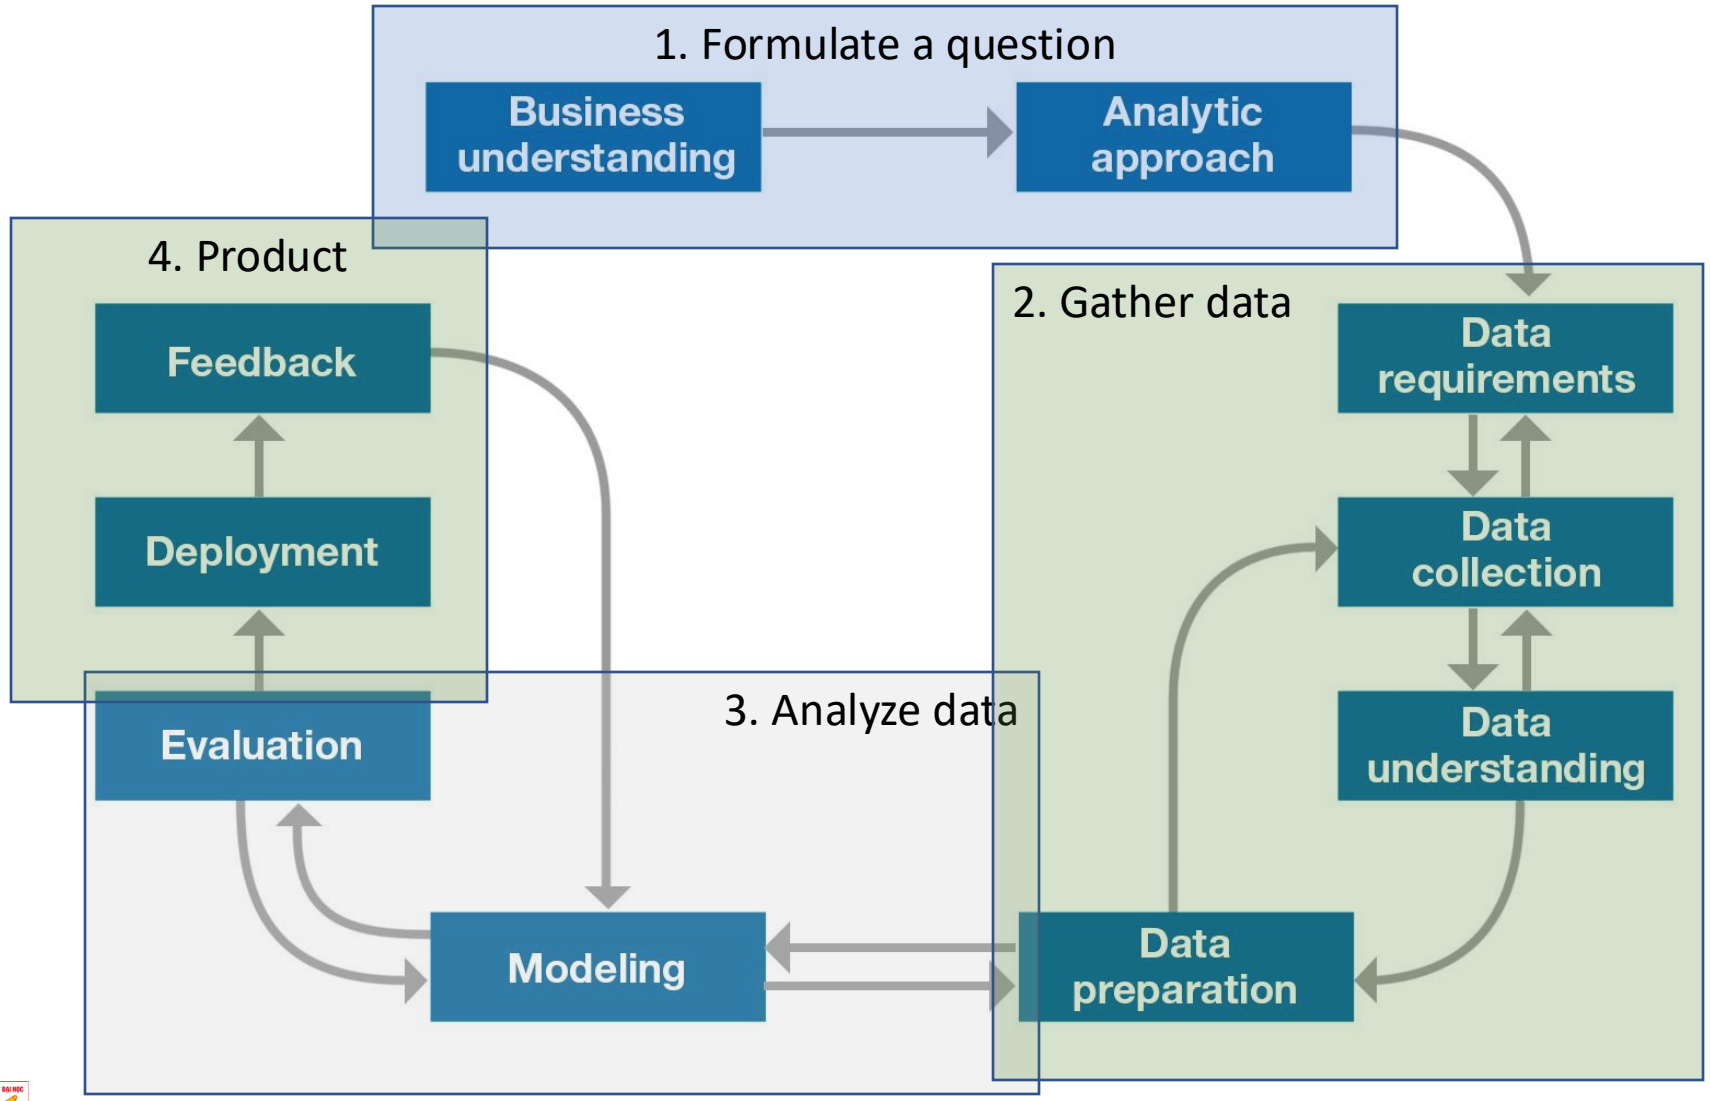

Source: *Foundational Methodology for Data Science*, IBM, 2015

DeepQA: Incremental Progress in Precision and Confidence 6/2007-11/2010

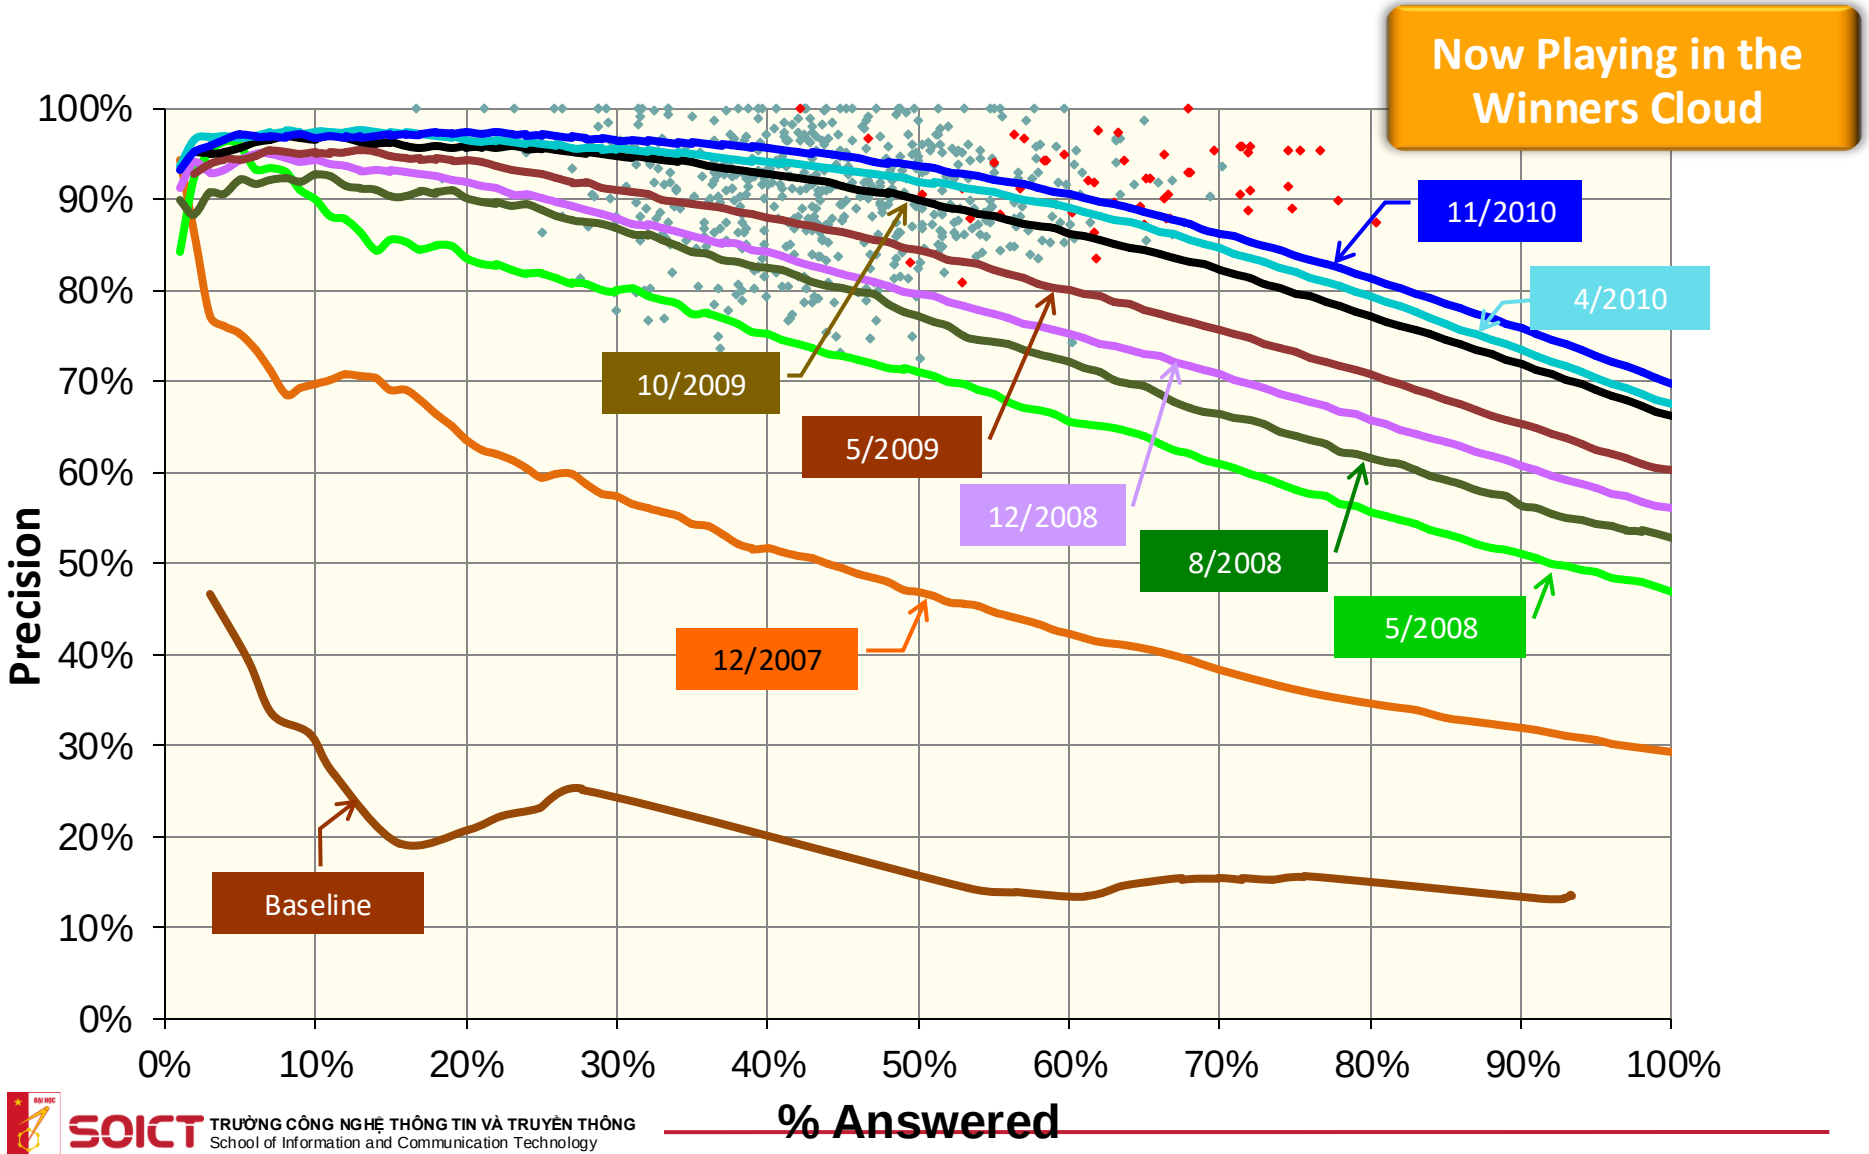

Làm sạch dữ liệu lớn: công việc tốn kém thời gian và công sức

- Chiếm khoảng 80% các công việc của nhà khoa học dữ liệu

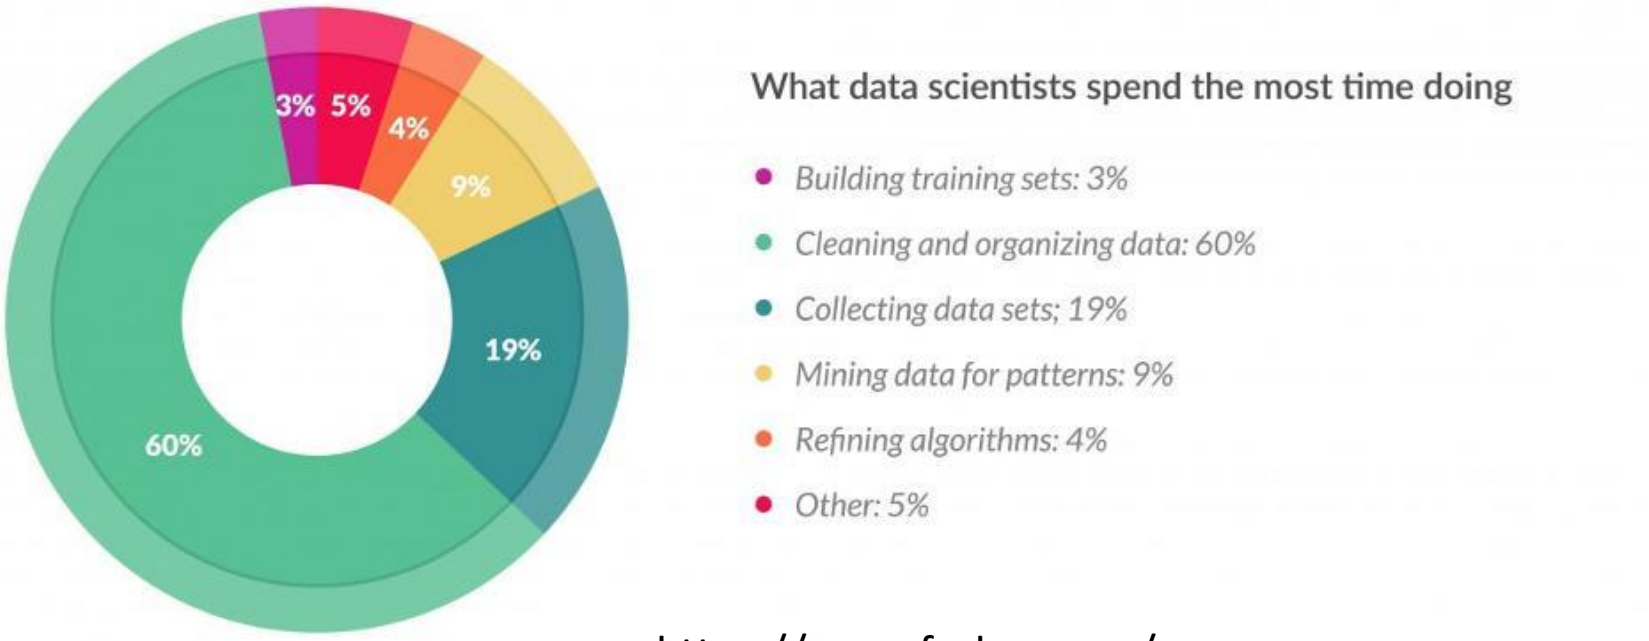

source: https://www.forbes.com/

Làm sạch dữ liệu lớn: công việc tốn kém thời gian và công sức

- 57% các nhà khoa học dữ liệu cho rằng đây là công việc kém thú vị

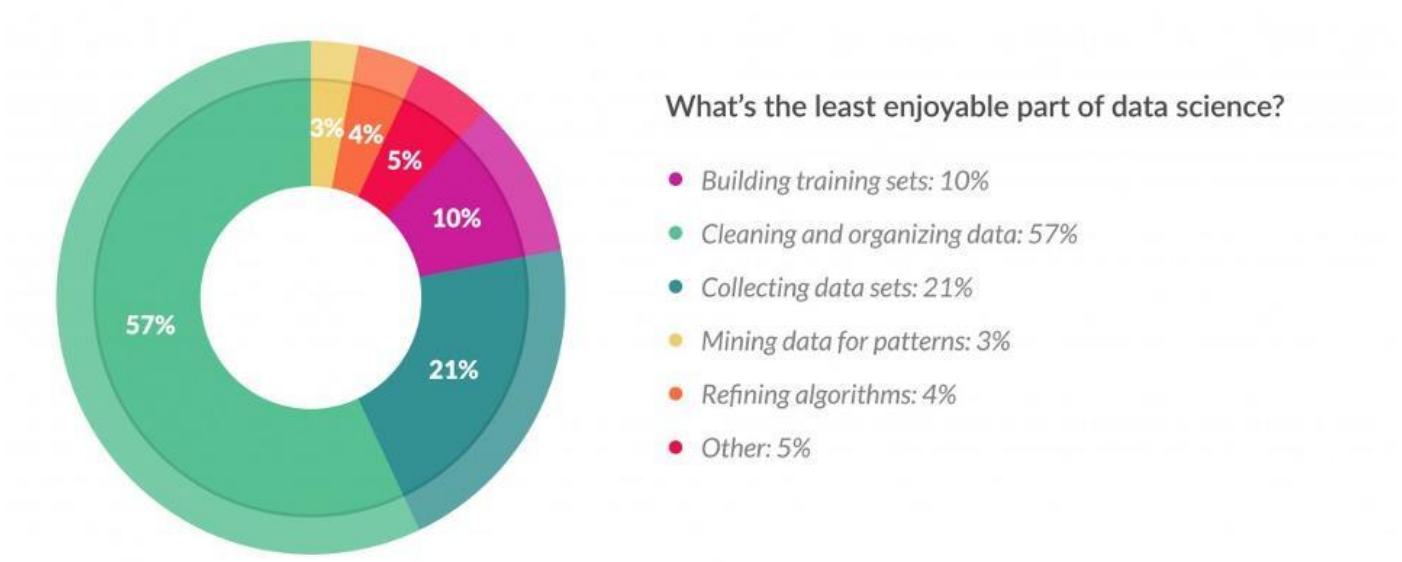

Tài liệu tham khảo

[1] Tiwari, Shashank. Professional NoSQL. John Wiley & Sons, 2011.

[2] Lam, Chuck. Hadoop in action. Manning Publications Co., 2010.

[3] Miner, Donald, and Adam Shook. MapReduce design patterns: building effective algorithms and analytics for Hadoop and other systems. " O'Reilly Media, Inc.", 2012.

[4] Karau, Holden. Fast Data Processing with Spark. Packt Publishing Ltd, 2013.

[5] Penchikala, Srini. Big data processing with apache spark. Lulu. com, 2018.

[6] White, Tom. Hadoop: The definitive guide. " O'Reilly Media, Inc.", 2012.

[7] Gandomi, Amir, and Murtaza Haider. "Beyond the hype: Big data concepts, methods, and analytics." International Journal of Information Management 35.2 (2015): 137-144.

[8] Cattell, Rick. "Scalable SQL and NoSQL data stores." Acm Sigmod Record 39.4 (2011): 12-27.

[9] Gessert, Felix, et al. "NoSQL database systems: a survey and decision guidance." Computer Science-Research and Development 32.3-4 (2017): 353-365.

[10] George, Lars. HBase: the definitive guide: random access to your planet-size data. " O'Reilly Media, Inc.", 2011.

[11] Sivasubramanian, Swaminathan. "Amazon dynamoDB: a seamlessly scalable non-relational database service." Proceedings of the 2012 ACM SIGMOD International Conference on Management of Data. ACM, 2012.

[12] Chan, L. "Presto: Interacting with petabytes of data at Facebook." (2013).

[13] Garg, Nishant. Apache Kafka. Packt Publishing Ltd, 2013.

[14] Karau, Holden, et al. Learning spark: lightning-fast big data analysis. " O'Reilly Media, Inc.", 2015.

[15] Iqbal, Muhammad Hussain, and Tariq Rahim Soomro. "Big data analysis: Apache storm perspective." International journal of computer trends and technology 19.1 (2015): 9-14.

[16] Toshniwal, Ankit, et al. "Storm@ twitter." Proceedings of the 2014 ACM SIGMOD international conference on Management of data. ACM, 2014.

[17] Lin, Jimmy. "The lambda and the kappa." IEEE Internet Computing 21.5 (2017): 60-66.

Các khoá học trực tuyến

- https://www.coursera.org/learn/nosql-database-systems
- https://who.rocq.inria.fr/Vassilis.Christophides/Big/index.htm
- https://www.coursera.org/learn/big-data-introduction?specialization=big-data
- https://www.coursera.org/learn/big-data-integration-processing?specialization=big-data
- https://www.coursera.org/learn/big-data-management?specialization=big-data
- https://www.coursera.org/learn/hadoop
- https://www.coursera.org/learn/scala-spark-big-data